кейс М.Видео

товар без заполненной характеристики не попадает в фильтры, и покупатель его не находит

наш пайплайн: текст карточки на входе, нормализованные атрибуты с уверенностью на выходе

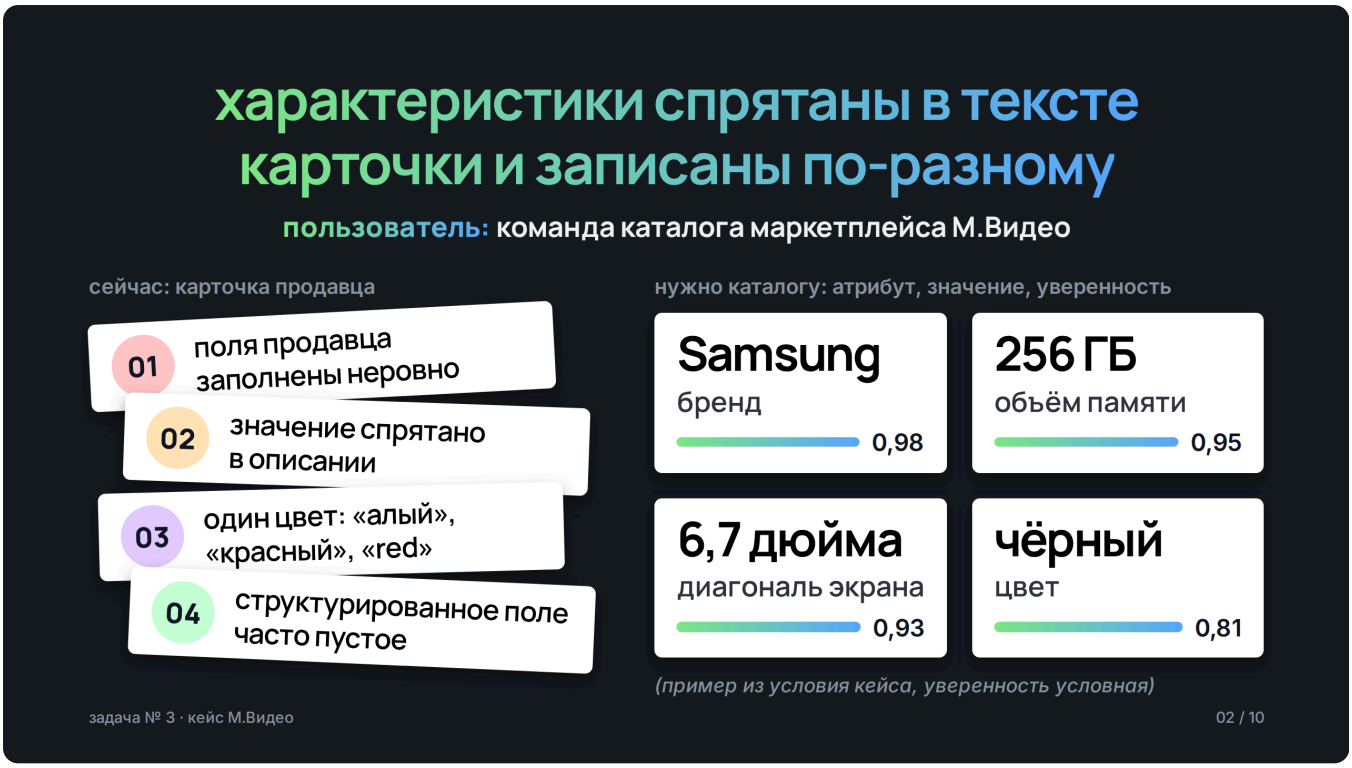
хакатон · задача № 3 · ИИ для заполнения характеристик товаров

слайд 01 / 10 · заметки докладчика

Начнём с простой вещи. Если в карточке не заполнена характеристика, товар не попадает в фильтры поиска. Покупатель ставит фильтр, скажем, «256 гигабайт», и товара просто нет в выдаче, хотя продавец его выставил.

В каталоге М.Видео тысячи категорий и десятки характеристик в каждой, новые товары и категории появляются каждый день, вручную это не заполнить.

Мы строим пайплайн, который берёт текст карточки и возвращает атрибуты в едином формате вместе с уверенностью. Дальше покажу, для кого это, как устроено и как мы поймём, что оно работает.

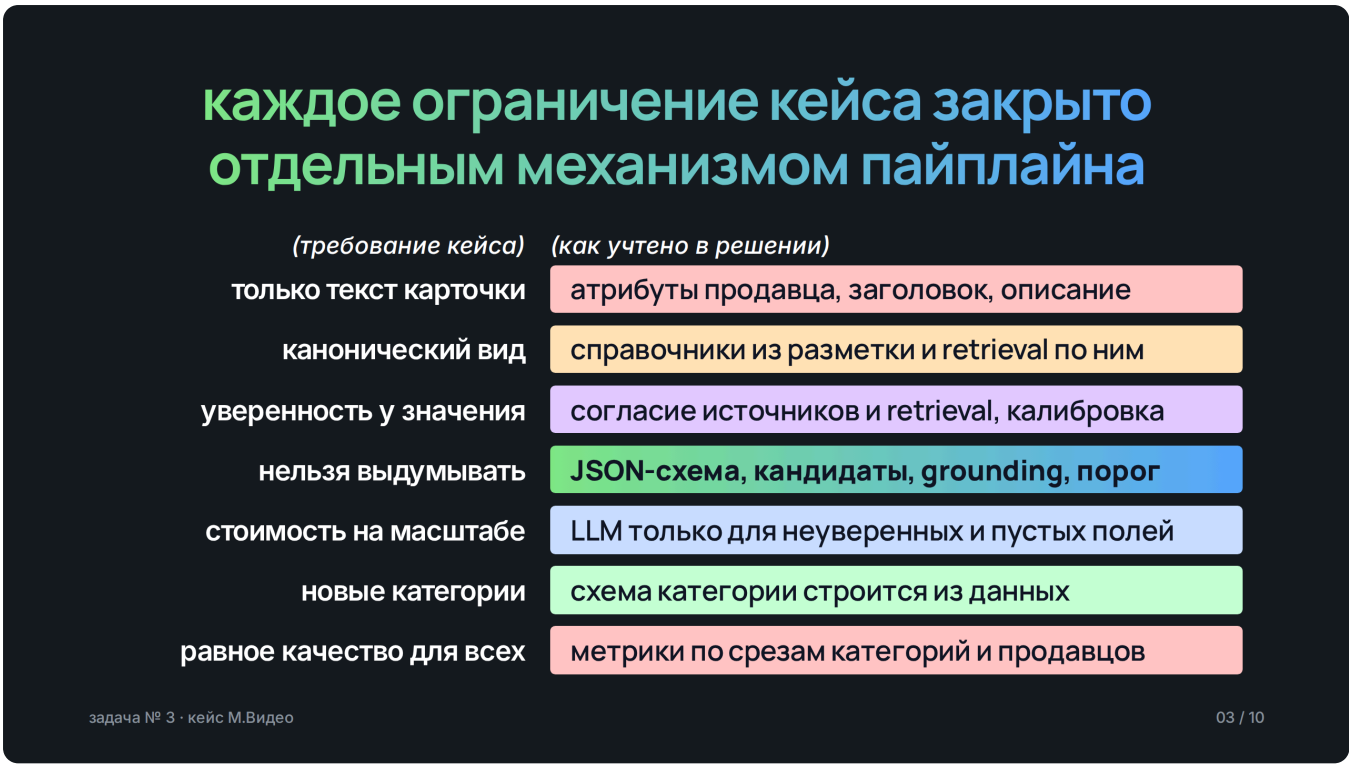


слайд 02 / 10 · заметки докладчика

Вот в чём проблема. Продавцы присылают карточки как придётся: что-то лежит в структурированных полях, а что-то только в свободном описании. Одно и то же значение пишут как «алый», «красный» или «red», и без нормализации фильтр по цвету это не склеит.

Справа то, что нужно каталогу: атрибут, каноническое значение и уверенность. Это пример из условия кейса, уверенность там условная.

Наш пользователь: команда каталога маркетплейса. Она получает уже заполненные атрибуты, а руками смотрит только сомнительные значения. Выигрывают от этого покупатели и продавцы, про это будет отдельный слайд.



слайд 03 / 10 · заметки докладчика

Теперь требования кейса и как мы закрываем каждое.

На вход только текст: атрибуты продавца, заголовок и описание, картинки не трогаем.

Значения приводим к каноническому виду через справочники, которые строим из размеченных данных, а сопоставляет с ними retrieval.

Уверенность считаем по согласию источников и скору retrieval и калибруем на валидации, чтобы 0,9 действительно значило «верно в девяти случаях из десяти».

Выделенная строка самая важная: решение не должно выдумывать. Поэтому LLM ограничена схемой, кандидатами из справочника и проверкой, что значение действительно есть в тексте.

Стоимость держим тем, что LLM вызывается только там, где без неё никак. Новые категории выдерживаем потому, что схема категории строится из данных, а не прописывается руками. И качество смотрим отдельными срезами по категориям и продавцам, чтобы не проседали хвост и мелкие продавцы.



слайд 04 / 10 · заметки докладчика

Почему именно каскад. Это таблица подходов из условия кейса, разложенная на две оси: по горизонтали стоимость инференса, по вертикали качество на хвосте. На каждой карточке ещё отмечено, как подход переносит новые категории.

Правила почти бесплатные, но на редких значениях слабые. LLM на хвосте сильная, но дорогая. NER и дообученный трансформер где-то посередине, и им нужно много размеченных данных.

И важная деталь справа: новые категории хорошо выдерживают только правила и LLM.

Поэтому мы не выбираем один подход, а соединяем дешёвый и сильный в каскад. Между ними работает retrieval по справочнику как нормализатор, его в исходной таблице нет.



слайд 05 / 10 · заметки докладчика

Сам пайплайн. Это каскад: идём по стрелкам, сначала верхний ряд слева направо, потом нижний справа налево. Каждый следующий шаг дороже и получает только то, что не закрыл предыдущий.

Первое: для категории строим схему, то есть какие атрибуты обязательны и какие у них допустимые значения. Всё это из размеченных данных.

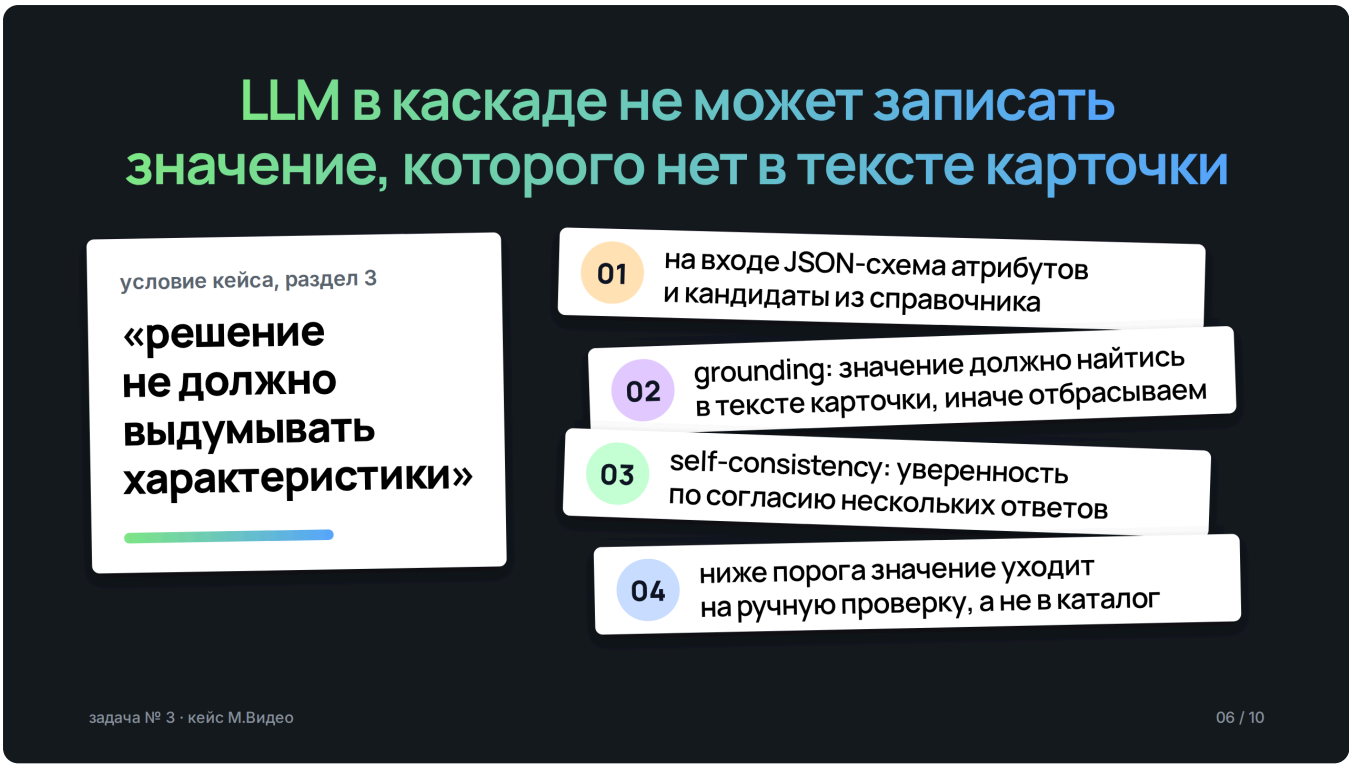
Второе: правила. Переносим атрибуты продавца, regex с конвертацией единиц для памяти, диагонали, батареи и оперативки, словари брендов и цветов.

Третье: retrieval на e5-small. Он крутится на CPU и сопоставляет текст карточки с каноническими значениями справочника.

Четвёртое: считаем уверенность по согласию источников и скору retrieval, калибруем на валидации.

И только если уверенность ниже порога или обязательное поле осталось пустым, подключается LLM.

Всё, что неуверенно и после неё, уходит на ручную проверку, а результаты проверки возвращаются в словари и правила. Это петля обратной связи, о которой просили в кейсе.



слайд 06 / 10 · заметки докладчика

Отдельно про галлюцинации, потому что в условии это назван главный риск. Ложный атрибут ломает фильтры и разносит ошибку по поиску.

Поэтому LLM у нас не генерирует свободно. На вход ей идёт JSON-схема и кандидаты из справочника, то есть выбирать она может только из допустимого.

Ответ проходит grounding: если значения нет в тексте карточки, мы его отбрасываем.

Уверенность считаем через self-consistency: спрашиваем несколько раз и смотрим, насколько ответы совпадают.

И если уверенность ниже порога, значение в каталог не попадает, а уходит человеку.



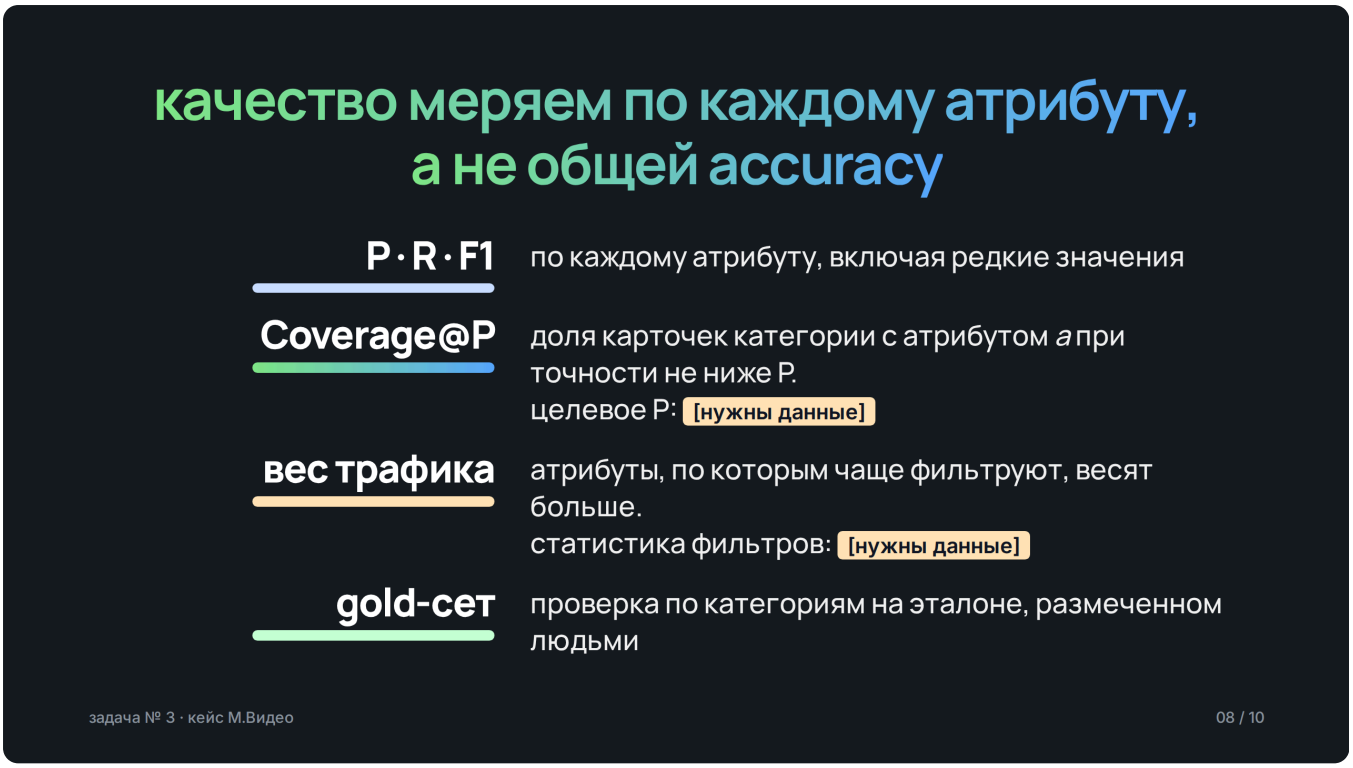
слайд 07 / 10 · заметки докладчика

Какую ценность это даёт. Цепочка взята прямо из условия: атрибут заполнен, товар попадает в фильтры, растут CTR и конверсия, и в итоге растёт GMV.

По ролям так. Покупатель находит товар через фильтры и сравнение. Продавец получает показы, даже если заполнил карточку неаккуратно, и это особенно важно для небольших продавцов: они не должны проигрывать крупным только из-за качества карточек.

Команда каталога тратит время только на сомнительные значения, а не на всё подряд.

А бизнес получает атрибуты, на которых держатся рекомендации, сопоставление одинаковых товаров разных продавцов, сравнение, ценообразование и ассортиментные решения.



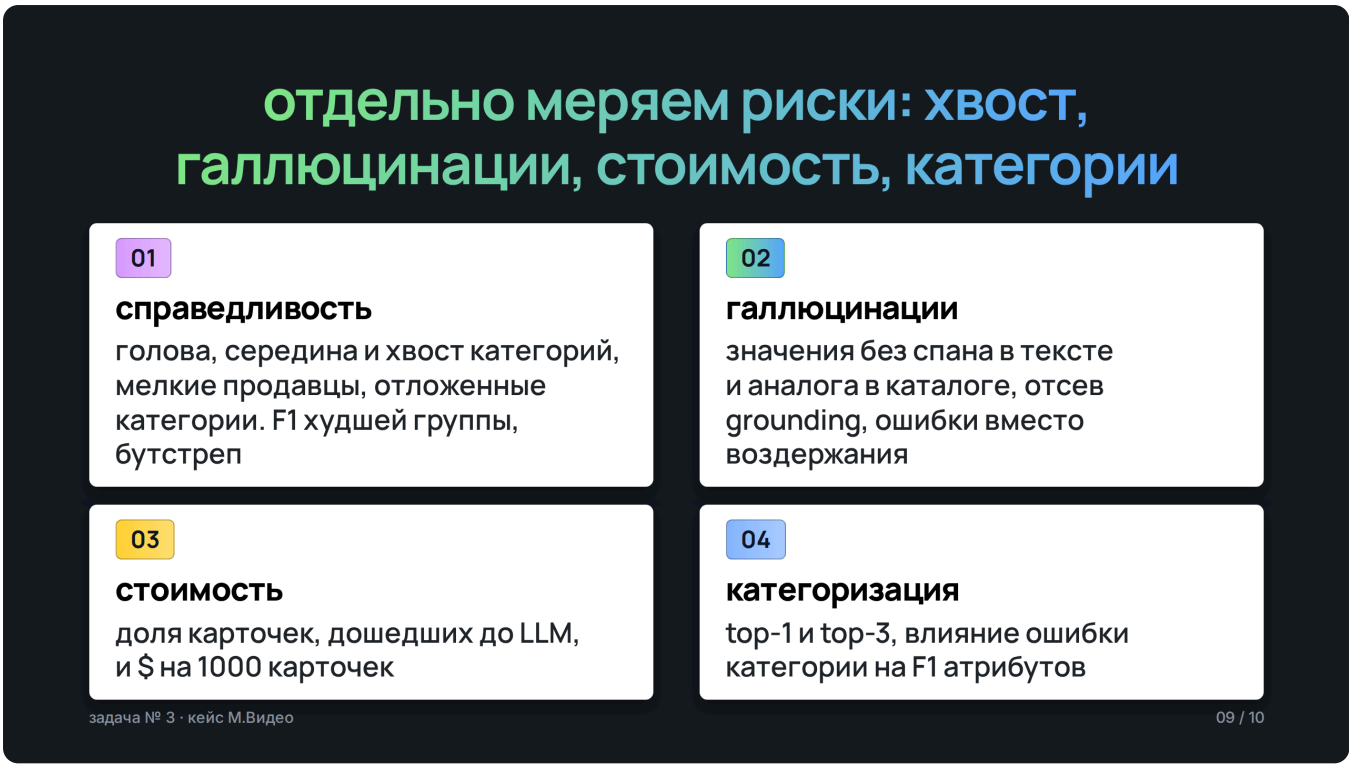
слайд 08 / 10 · заметки докладчика

Как поймём, что работает. Общая accuracy тут не подходит: она хорошая на частых значениях и прячет провалы на редких. Поэтому precision, recall и F1 считаем по каждому атрибуту отдельно.

Главная продуктовая метрика: coverage при заданной точности. То есть какую долю карточек категории мы заполняем, не опускаясь ниже нужного уровня точности. Сам уровень P хотим согласовать с вами, сейчас его нет.

Дальше взвешиваем по трафику: атрибуты, по которым чаще фильтруют, важнее. Для этого нужна статистика использования фильтров.

И всё это проверяем на gold-сете отдельно по категориям.



слайд 09 / 10 · заметки докладчика

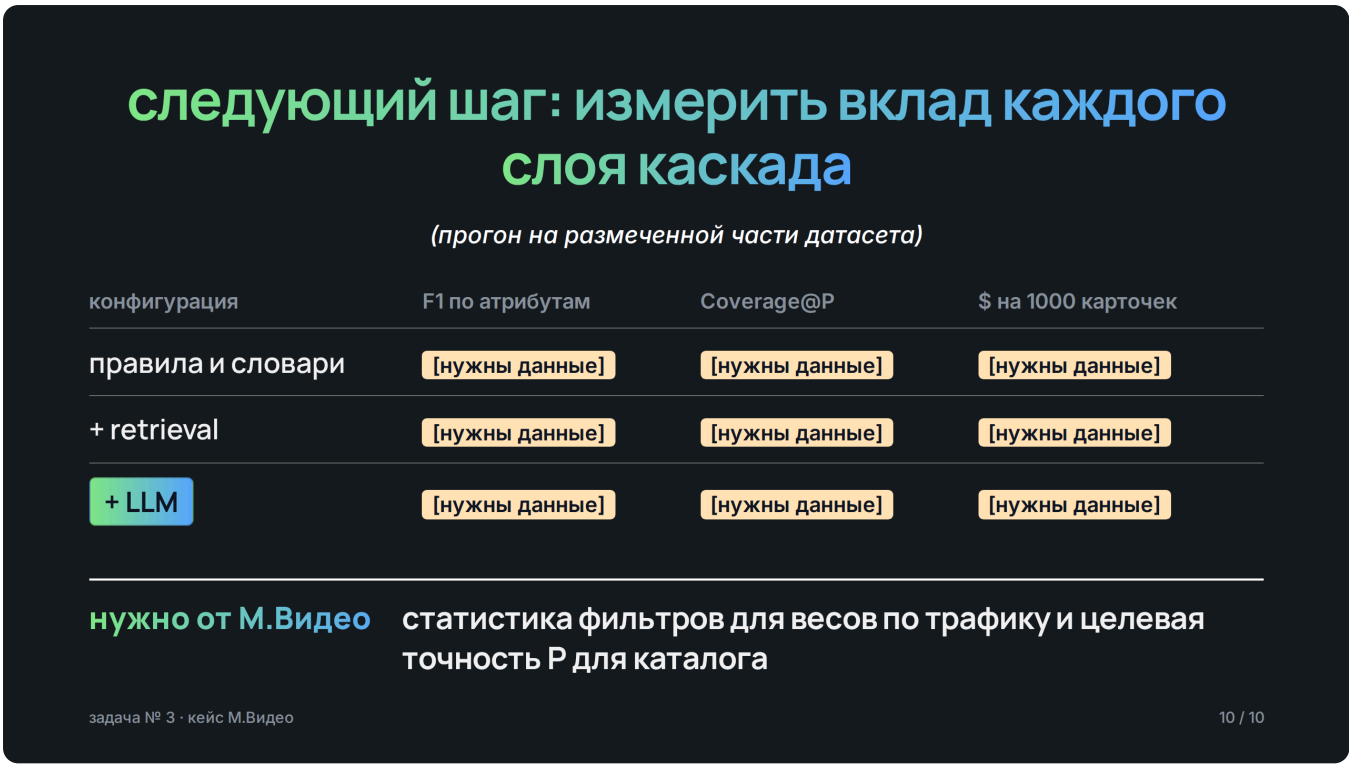
И метрики рисков, про которые просили рассказать на защите.

Справедливость: режем по голове, середине и хвосту категорий, по крупным и мелким продавцам и по отложенным категориям, которых модель не видела. Смотрим F1 худшей группы и разрыв с головой. В хвосте мало примеров, поэтому доверительные интервалы считаем бутстрепом.

Галлюцинации: доля значений без доказательства, то есть нет ни спана в тексте, ни аналога в каталоге. Плюс сколько отсекла проверка grounding и ошибки там, где модель должна была воздержаться.

Стоимость: какая доля карточек дошла до LLM и сколько долларов уходит на тысячу карточек.

И категоризация: top-1 и top-3, и насколько ошибка категории тянет вниз F1 атрибутов.



слайд 10 / 10 · заметки докладчика

Что дальше. Ближайший шаг: прогнать каскад послойно на размеченной части и заполнить эту таблицу. Так будет видно, что даёт каждый слой: сколько качества добавляет retrieval, сколько LLM и во что это обходится.

Цифр здесь пока нет, и мы их не придумываем. Для слоя с LLM дополнительно покажем, какая доля карточек до неё дошла.

Чтобы считать метрики так, как их считает бизнес, нам от вас нужны две вещи: статистика использования фильтров, чтобы взвесить атрибуты по трафику, и целевая точность, с которой значение можно пускать в каталог без ручной проверки.